

Aprendizaje Automático: Práctica 2

David Cabezas Berrido

Índice

1. Ejercicio sobre la complejidad de H y el ruido	2
1.1. Dibujar nubes de puntos	2
1.2. Muestra etiquetada por una recta	2
1.3. Comparación con otras funciones frontera	3

1. Ejercicio sobre la complejidad de H y el ruido

1.1. Dibujar nubes de puntos

Utilizando las funciones `simula_unif` y `simula_gaus`, he generado dos muestras en dimensión 2, de tamaño $N = 50$.

La primera muestra es una uniforme en el cuadrado $[-50, 50] \times [-50, 50]$ y la segunda muestra es una normal de media $(0, 0)$ y varianza $(5, 7)$ (desviación típica $(\sqrt{5}, \sqrt{7})$).

He mantenido fija la escala de los ejes para que se aprecie que los puntos generados por la normal están mucho más concentrados en torno al punto $(0, 0)$, la concentración es ligeramente mayor en el eje de abscisas debido a que tiene menor varianza, pero apenas se aprecia.




Figura 1: Muestras uniforme y normal

1.2. Muestra etiquetada por una recta

He generado (con `simula_unif`) una muestra de $N = 100$ puntos del cuadrado $[-50, 50] \times [-50, 50]$ y los he etiquetado con el signo de la distancia a una recta generada por `simula_recta` que corta a dicho cuadrado. Esto quiere decir que si la recta es $y = ax + b$, la etiqueta de un punto (x, y) es el signo de la función $y - ax - b$ (+1 si el punto queda por encima de la recta y -1 si queda por debajo). Obviamente la recta clasifica a la perfección todos los puntos.

A continuación, he añadido ruido a las etiquetas de la muestra (10% en cada clase). Claramente la recta tiene un 10% de puntos mal clasificados ahora.

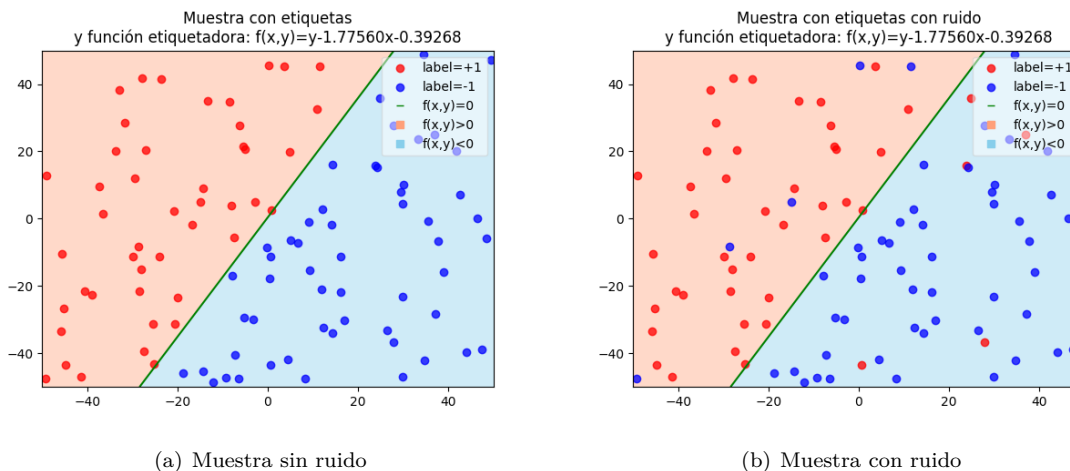
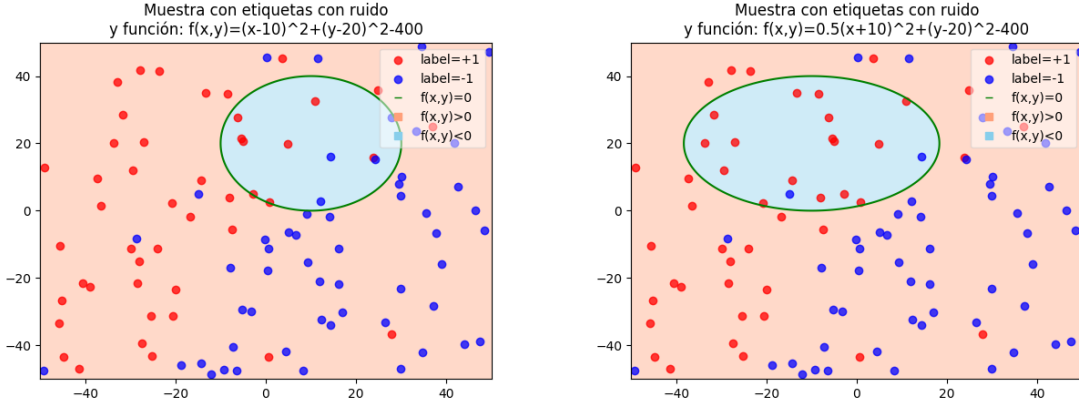


Figura 2: Muestra y recta etiquetadora

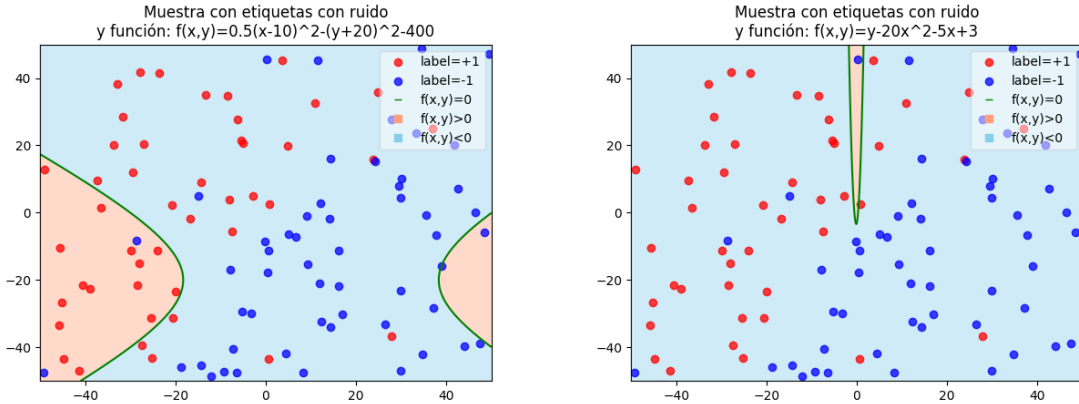
1.3. Comparación con otras funciones frontera

Ahora he representado la misma muestra (con ruido) junto con otras funciones, he calculado también el error que cometen dichas funciones al clasificar la muestra.

En la siguiente figura se ve que puntos clasifica bien y mal cada función, los bien clasificados son los que están en la región de su color. Incluyo también el porcentaje de puntos mal clasificados para cada función.



(a) $f(x, y) = (x - 10)^2 + (y - 20)^2 - 400$; Error: 58 % (b) $f(x, y) = 0.5(x + 10)^2 + (y - 20)^2 - 400$; Error: 68 %



(c) $f(x, y) = 0.5(x - 10)^2 - (y + 20)^2 - 400$; Error: 35 % (d) $f(x, y) = y - 20x^2 - 5x + 3$; Error: 47 %

Figura 3: Muestra con otras funciones como delimitadores

Ninguna de estas cuatro funciones ha conseguido si quiera acercarse al error del 10 % que presentaba la recta. Esto era de esperar, ya que la recta la he usado para etiquetar la muestra (salvo ese 10 % de ruido) y las funciones estaban prefijadas antes (no han recibido ningún aprendizaje ni ajuste).

Sin embargo, es perfectamente posible que el ruido de la muestra provoque que el mejor ajuste no sea la misma recta que usé para etiquetarla, en este caso se puede producir sobreajuste si la clase H es lo suficientemente compleja como para ajustar el ruido.

Por ejemplo, si ajustase la muestra sin ruido mediante una parábola $y = ax^2 + bx + c$ el peso a obtendría un valor muy cercano a 0. Pero en la muestra con ruido, esto puede no ocurrir, es probable que el valor que se obtenga para a al ajustar la muestra con ruido no sea cercano a 0, lo que ajustaría mejor la muestra (con ruido) pero se alejaría de la función objetivo, dando lugar a sobreajuste.