Aprendizaje Automático: Proyecto Final
Devanagari Handwritten Characters

David Cabezas Berrido y Patricia Córdoba Hidalgo

Índice

1. Problema

El problema a resolver consiste en clasificar caracteres de la escritura Devanagari. Nuestros datos son imágenes de estos símbolos escritos a mano, cada uno de ellos con una etiqueta especificando el símbolo que representa la imagen.

Inicialemente, nuestro espacio de características $\mathcal{X}$ está formado por imágenes de 32×32 píxeles cada una, con un marco de 2 píxeles por cada uno de los 4 lados. El conjunto de etiquetas, Y son los 46 caracteres que consideramos, 36 letras y 10 dígitos (del 0 a 9). La función objetivo f que buscamos es aquella que a una cuadrícula de píxeles representando un símbolo Devanagari manuscrito le haga corresponder la clase del símbolo correspondiente.

2. Dataset. Conjuntos de train y test

El conjunto de datos de los que disponemos
https://archive.ics.uci.edu/ml/datasets/Devanagari+Handwritten+Character+Dataset consta de 92000 instancias (imágenes etiquetadas), 2000 de cada una de las 46 clases. Los datos vienen divididos en train: 78200 instancias (85 %), 1700 por clase; y test: 13800 instancias (15 %), 300 por clase.

Existen algunos artículos y proyectos relativos a este dataset, por lo que mantener esta división entre train y test nos permitirá comparar los resultados que logren nuestros modelos y procesamiento con los resultados de otros diseñados por terceros. También sabemos que no existen datos perdidos y las clases están perfectamente balanceadas.

En la descripción del dataset se informa de que estos datos proceden de documentos escritos, pero desconocemos su procedencia y sus autores. En problemas de reconocimiento de símbolos manuscritos existe la dificultad de que un modelo aprenda a reconocer símbolos de un único autor o un conjunto de autores, lo que conlleva sobreajuste y a estimaciones por validación poco fiables, ya que la muestra de entrenamiento no termina de ser representativa y el modelo se adapta a ese sesgo. En nuestro caso, desconocemos si los datos de train y test corresponden a símbolos trazados por distintas personas o no, con lo que tenemos otra razón más para respetar la partición de conjuntos de train y test existente.

Extraemos un conjunto de validación del 30 % de los datos de entrenamiento para consultar la eficacia práctica de ciertas decisiones que tomamos durante el preprocesamiento, así como para estimar los hiperparámetros usados en cada modelo. Esto nos deja con 54740 (70 %) datos para entrenar cada alternativa y 23460 datos para validar. Debido a la abundancia de datos, podemos esperar que los scores obtenidos al validar sean representativos de la bondad real de un modelo o procesamiento, así que decidimos no usar validación cruzada, ya que es computacionalmente muy costosa y el ajuste de los modelos es lento debido a la cantidad de datos.

Para ello usamos la función `train_test_split` de *sklearn* e indicamos mediante la opción `stratify` que queremos preservar la proporción de elementos de cada clase en cada uno de los conjuntos, de forma que sigan perfectamente balanceadas.

2.1. Formato de los datos

En el fichero `png_to_np.py`, guardamos las imágenes, originalmente en formato `png`, como array. Para ello leemos cada imagen como array de escala de grises usando la función `imread` de *matplotlib* y eliminamos los dos píxeles de marco por cada lado, quedándonos con matrices de 28×28 de valores flotantes entre 0 y 1 representando la intensidad de gris en cada pixel. El resultado es guardado en disco, lo hacemos con la función `saveGrey`, que usa la función `savez_compressed` de *numpy* para almacenarlo en formato `npz`.

Este fichero solo se ejecuta una vez para cambiar el formato de los datos. Tras esto, podemos usar los datos guardados en disco para las sucesivas ejecuciones del código. Proporcionamos los datos ya transformados, aunque en el fichero `main.py` se puede alterar la variable `PNG_TO_NP` para ejecutar el script que carga las imágenes y almacena estos datos en disco.

3. Preprocesamiento

Preprocesamos los datos usando las funciones implementadas en el fichero `preprocessing.py`. El preprocesamiento se realiza imagen a imagen, siendo el resultado sólo dependiente de la propia imagen y por tanto paralelizable. Esta

independencia hace que sea indiferente extraer los datos para validación antes o después del preprocesamiento. Para cada imagen realizamos dos operaciones:

3.1. Centrado y reescalado

Esta operación la realiza la función `centerAndResize`. Ante una imagen, calculamos un umbral con la ayuda del método de Otsu para thresholding (usando la función `threshold_otsu` de la librería *skimage*).

Para calcular la caja englobante del carácter, usamos el closing (función `closing` de *skimage*) de la imagen resultante de considerar los píxeles con intensidad superior a este umbral. Recortamos el exterior de la caja y reescalamos la imagen a `WIDTH` $\times$ `WIDTH` para trabajar con un tamaño de imagen unificado (función `resize` de *skimage*).

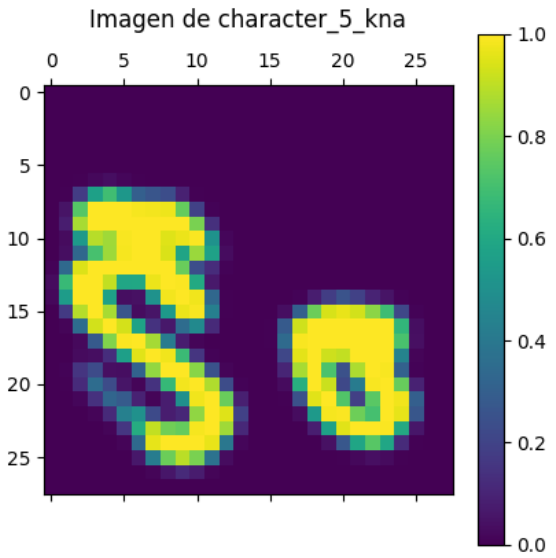

(a) Muestra antes del preprocesado

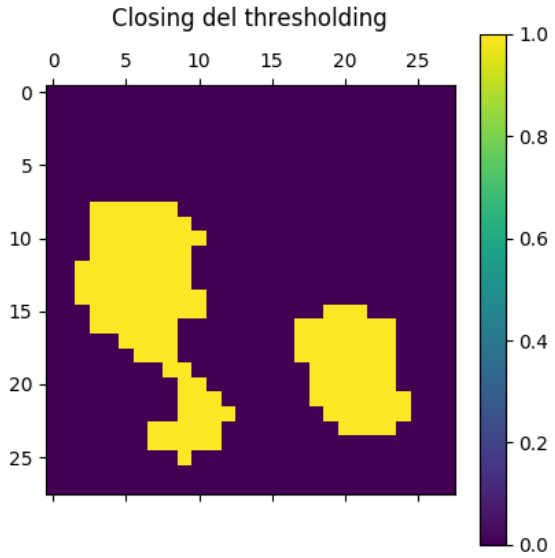

(b) Thresholding y closing

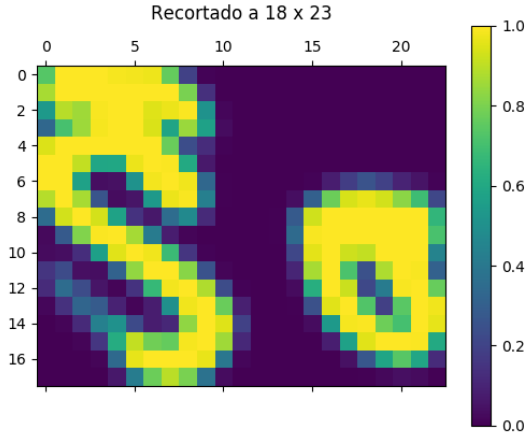

(c) Recortado de la caja englobante

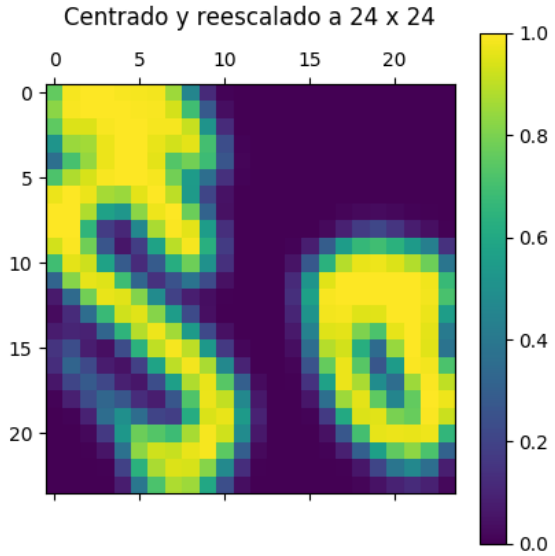

(d) Reescalado

Figura 1: Proceso de centrado y reescalado sobre una instancia correspondiente al carácter kna

3.2. Downsampling

Para reducir la dimensionalidad, realizamos un downsampling o reducción por bloques de la imagen, agrupando cada bloque de 4 píxeles en uno usando la media de sus valores. Esta reducción se lleva a cabo con la función `block_reduce` de *skimage*.

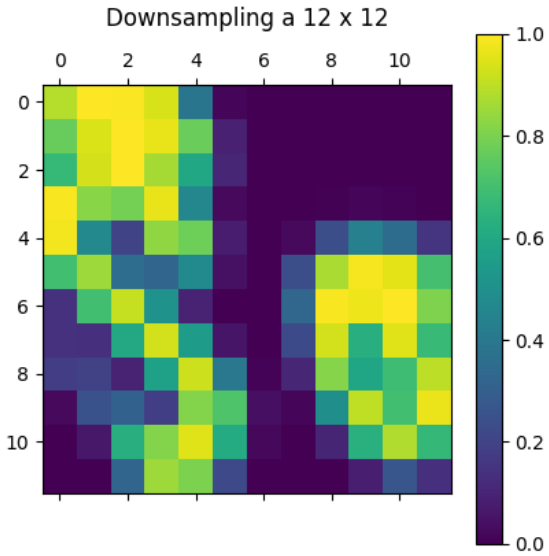

Figura 2: Resultado del preprocesamiento (tras combinar centrado y reescalado con downsampling)